Detecção de intrusão em redes com a base NSL-KDD

Relatório do projeto — análise exploratória e pré-processamento (Etapas 1 e 2)

Grupo 5 · Daniel Alves Gonçalves, Daniel Pedrosa Collina, Izadora Galarza Alves, Larissa Varella Araújo, Samuel Ferreira Alves Vieira

7 de novembro de 2026

69.833	5,84%	20	0,974
registros de treino, 50 colunas	de anomalias (16,1 normais para cada anomalia)	configurações de pré-processamento × modelo (23 execuções)	melhor F1-macro sem atributos suspeitos (RF, validação cruzada)

1 Resumo

O objetivo é classificar conexões de rede como `normal` ou `anomaly`, com o F1-macro como métrica oficial. Na Etapa 1, caracterizamos a base e identificamos ausências, duplicatas, rótulos conflitantes, valores fora do domínio e três atributos com forte suspeita de vazamento. Na Etapa 2, comparamos, uma família de decisão por vez, seis estratégias de limpeza, quatro codificações, quatro transformações numéricas, três cenários de balanceamento e PCA, sempre com o pré-processamento ajustado dentro de cada dobra de treino.

A configuração de referência — limpeza completa sem os atributos suspeitos, *one-hot* com categorias raras agrupadas, padronização e Random Forest — alcançou F1-macro de **0,9742 ± 0,0049**. Para a Regressão Logística, a transformação logarítmica foi a melhor (0,9379). SMOTENC e a ausência de balanceamento empataram; RandomUnderSampler e PCA pioraram o resultado. A principal ressalva é metodológica: a remoção de rótulos conflitantes antes da validação cruzada retirou quase metade das anomalias restantes e torna as estimativas otimistas em relação ao teste (Seção 6).

2 Base de dados e diagnóstico (Etapa 1)

O arquivo `treino.csv` tem 69.833 linhas, 49 atributos e a classe: 65.754 normais e 4.079 anomalias. Um classificador que respondesse sempre `normal` teria 94,2% de acurácia e F1-macro de apenas 0,485, por isso a acurácia não orienta nenhuma escolha. Além dos 41 atributos canônicos do NSL-KDD [1], a base traz campos derivados e operacionais. Os principais problemas encontrados foram:

- **Ausências:** 8,38% das células, concentradas em `tempo_resposta_analista_min` (91,4%) e `src_bytes` (40,0%); `service` e `flag` têm cerca de 6% de ausentes, com taxa semelhante nas duas classes.
- **Redundâncias:** 11.355 duplicatas exatas; 1.702 grupos com atributos idênticos e rótulos diferentes (3.730 linhas); colunas derivadas sem informação nova (`src_bytes_kb`, `dst_bytes_kb`, `total_bytes`, `same_srv_pct`, `protocolo_cod`), uma constante (`num_outbound_cmds`) e uma quase constante (`is_host_login`, com apenas 2 valores diferentes de zero).
- **Inconsistências:** contagens acima dos limites definidos no NSL-KDD (`count`, `srv_count`, `dst_host_count`), taxas fora de [0, 1] e durações e bytes negativos; categorias com caixa e espaços diferentes — `service` tem 96 níveis brutos, mas 67 após `strip` e `lower`.
- **Vazamento:** `tipo_alerta_soc`, `score_ids_legado` e `tempo_resposta_analista_min` descrevem a resposta operacional a um alerta, informação que provavelmente não existe no momento da previsão. Sozinhos, numa árvore de profundidade 2, alcançam F1-macro de 0,862, 0,797 e 0,799, contra 0,485 do classificador trivial. Foram excluídos do modelo.

3 Protocolo experimental

Apenas `treino.csv` é usado nos experimentos; o conjunto de teste não participa de nenhum ajuste. As regras determinísticas (padronizar categorias, converter valores fora do domínio em ausentes e remover colunas) são aplicadas igualmente a treino e teste. Tudo o que aprende com os dados — imputação por moda/mediana, codificação, escala, PCA e balanceamento — fica dentro de um `imblearn.Pipeline` e é ajustado só na parcela de treino de cada dobra; a validação mantém sua distribuição original.

A validação usa `StratifiedGroupKFold` com três dobras, embaralhamento (`shuffle=True`) e semente 42, agrupando linhas com atributos idênticos para que uma cópia no treino não revele a resposta da outra na validação. Interpreta-

mos a regra “não re-embaralhar nem criar um split próprio” como proibição de redividir os arquivos oficiais; a validação cruzada dentro do treino é a seleção exigida pelo enunciado. Os modelos de referência são Random Forest (100 árvores), pouco sensível à escala, e Regressão Logística, sensível a ela. Cada experimento parte da configuração de controle (limpeza F, *one-hot* com raras agrupadas, *standard*, sem balanceamento e sem redução) e altera um único eixo. A exceção é o balanceamento: os três cenários usam codificação ordinal, que o SMOTENC exige, então a comparação entre eles é justa, mas não parte exatamente do controle.

4 Resultados e justificativas

4.1 Dados redundantes e inconsistentes

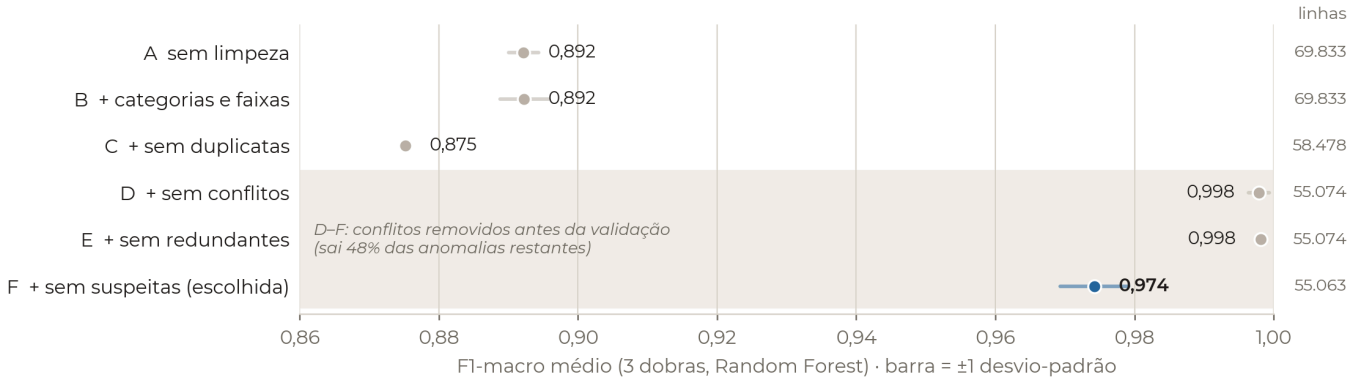


Figura 1. Estratégias cumulativas de limpeza (A–E mantêm os atributos suspeitos; F os remove). A queda de E para F mede a contribuição dos atributos suspeitos; o salto de C para D vem da remoção dos grupos conflitantes, mantida em E e F.

Padronizar categorias e mascarar valores impossíveis não mudou o resultado (A = B = 0,892), mas são correções de representação necessárias para que o teste seja tratado da mesma forma. Remover duplicatas reduziu levemente o F1 (C = 0,875), provavelmente porque, sem as cópias, os pares conflitantes passam a pesar mais (3.404 de 58.478 linhas). O salto para 0,998 em D vem da remoção dos 1.702 grupos conflitantes: cada grupo tem uma linha normal e uma anômala com atributos idênticos, que nenhum modelo consegue separar. Isso retira 1.702 das 3.519 anomalias restantes. A remoção dos atributos suspeitos (E → F) custa 0,024 de F1-macro, o que confirma que eles carregam informação do rótulo. Adotamos F por ser a única estratégia sem esses atributos.

4.2 Conversão simbólico-numérica

Depois da limpeza, `service` tem 65 níveis, 48 deles com menos de 0,1% das linhas. Alguns serviços pouco frequentes, mas acima desse limiar, são muito informativos: `private` (1.759 linhas) tem 34,5% de anomalias, `ecr_i` (211) 32,7% e `eco_i` (401) 25,2%, contra 0,4% em `http`; no *one-hot* com raras agrupadas, eles mantêm coluna própria. Com Regressão Logística, o *one-hot* com níveis abaixo de 0,1% agrupados num nível “infrequente” foi o melhor (0,9322), empatado com o *one-hot* puro (0,9305) e com menos colunas (Figura 2, à esquerda). Ordinal (0,9073) e frequência (0,8997) reduzem cada serviço a um único número; o modelo linear não consegue isolar esses serviços, e o ordinal ainda impõe uma ordem alfabética sem significado. No notebook da Parte 2 (5 dobras), com Random Forest, as quatro codificações empataram (0,974 a 0,977), pois árvores separam categorias por limiares. Assim, usamos *one-hot* com raras agrupadas como padrão e ordinal apenas onde é exigido (SMOTENC). Entre as dobras surgiram 2 níveis novos de `service` e 1 de `flag`; por isso o codificador trata categorias desconhecidas.

4.3 Transformação numérica

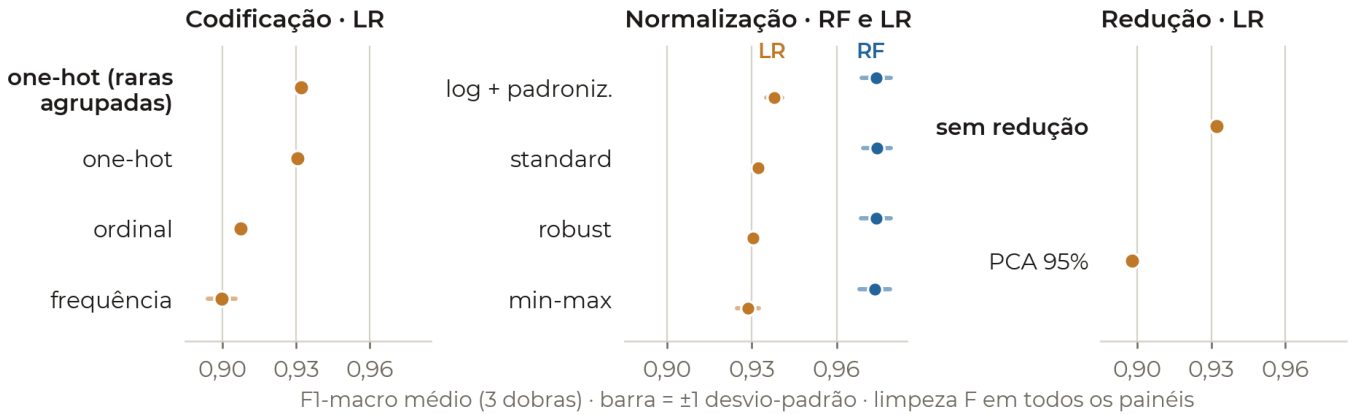


Figura 2. Efeito de cada técnica, mudando uma decisão por vez a partir da configuração de controle. Ocre: Regressão Logística; azul: Random Forest; em negrito, a opção adotada. Diferenças menores que a barra de desvio-padrão são tratadas como empate.

No Random Forest, as quatro transformações ficaram entre 0,9735 e 0,9742, diferença menor que um desvio-padrão: árvores dependem só da ordem dos valores. Na Regressão Logística, `log` — *sinal(x)·log(1+|x|)* seguido de padronização — foi a melhor (0,9379, contra 0,9322 do *standard* e 0,9287 do *min-max*), provavelmente porque bytes e durações têm caudas longas, que a compressão logarítmica reduz; não testamos essa explicação diretamente.

4.4 Balanceamento

Os métodos rodam só no treino de cada dobra. O SMOTENC, que gera exemplos sintéticos tratando os atributos categóricos como categorias [2], elevou o recall de `anomaly` de 0,906 para 0,931 ao custo de precisão (0,988 → 0,965); o F1-macro ficou empatado (0,9731 contra 0,9718, diferença menor que o desvio de 0,0053). O RandomUnderSampler descarta cerca de 97% dos exemplos normais de treino: detecta 98,0% das anomalias, mas com precisão de 0,661, e o F1-macro cai para 0,8897 (Figura 3).

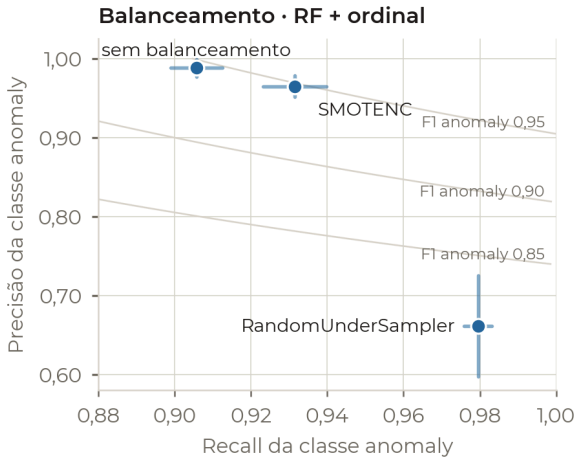


Figura 3. Precisão × recall da classe `anomaly` nos três cenários de balanceamento (Random Forest, codificação ordinal). Barras: ±1 desvio-padrão entre as dobras. As curvas cinza ligam pontos de mesmo F1 dessa classe.

4.5 Redução de dimensionalidade

PCA mantendo 95% da variância reduziu o F1-macro da Regressão Logística de 0,9322 para 0,8979 e o recall de `anomaly` de 0,798 para 0,700. Uma explicação provável, não testada, é que o PCA preserva as direções de maior variância, dominadas pelo tráfego normal, e pode descartar direções de baixa variância úteis para separar ataques (Figura 2, à direita). Não foi adotado.

5 Tabela comparativa

Todas as 23 execuções (20 configurações distintas), por etapa e ordenadas por F1-macro (média ± desvio-padrão em 3 dobras). Em azul, a configuração de controle, que reaparece em várias etapas com o mesmo resultado, o que confirma que as execuções são reprodutíveis. Em cinza, estratégias de limpeza que mantêm atributos suspeitos de vazamento (não elegíveis).

ETAPA	LIMP.	CODIFICAÇÃO	ESCALA	BALANC.	REDUÇÃO	MOD.	F1-MACRO	PREC. ANOM.	REC. ANOM.
Limpeza	E	one-hot raras	standard	—	—	RF	0,9981 ± 0,0004	0,997	0,996
Limpeza	D	one-hot raras	standard	—	—	RF	0,9979 ± 0,0015	0,996	0,996
Limpeza	F	one-hot raras	standard	—	—	RF	**0,9742** ± 0,0049	0,990	0,913
Limpeza	B	one-hot raras	standard	—	—	RF	0,8922 ± 0,0035	0,769	0,829
Limpeza	A	one-hot raras	standard	—	—	RF	0,8922 ± 0,0021	0,769	0,828
Limpeza	C	one-hot raras	standard	—	—	RF	0,8751 ± 0,0002	0,735	0,799
Codificação	F	one-hot raras	standard	—	—	LR	**0,9322** ± 0,0007	0,953	0,798
Codificação	F	one-hot	standard	—	—	LR	**0,9305** ± 0,0005	0,952	0,793
Codificação	F	ordinal	standard	—	—	LR	**0,9073** ± 0,0023	0,932	0,733
Codificação	F	frequência	standard	—	—	LR	**0,8997** ± 0,0055	0,933	0,708
Normalização	F	one-hot raras	standard	—	—	RF	**0,9742** ± 0,0049	0,990	0,913
Normalização	F	one-hot raras	log	—	—	RF	**0,9741** ± 0,0051	0,989	0,913
Normalização	F	one-hot raras	robust	—	—	RF	**0,9739** ± 0,0054	0,989	0,913
Normalização	F	one-hot raras	min-max	—	—	RF	**0,9735** ± 0,0054	0,989	0,911
Normalização	F	one-hot raras	log	—	—	LR	**0,9379** ± 0,0029	0,952	0,817
Normalização	F	one-hot raras	standard	—	—	LR	**0,9322** ± 0,0007	0,953	0,798
Normalização	F	one-hot raras	robust	—	—	LR	**0,9304** ± 0,0019	0,952	0,793
Normalização	F	one-hot raras	min-max	—	—	LR	**0,9287** ± 0,0039	0,956	0,785
Balanceamento	F	ordinal	standard	SMOTENC	—	RF	**0,9731** ± 0,0053	0,965	0,931
Balanceamento	F	ordinal	standard	—	—	RF	**0,9718** ± 0,0045	0,988	0,906

ETAPA	LIMP.	CODIFICAÇÃO	ESCALA	BALANC.	REDUÇÃO	MOD.	F1-MACRO	PREC. ANOM.	REC. ANOM.
Balanceamento	F	ordinal	standard	RUS	—	RF	**0,8897** ± 0,0240	0,661	0,980
Redução	F	one-hot raras	standard	—	—	LR	**0,9322** ± 0,0007	0,953	0,798
Redução	F	one-hot raras	standard	—	PCA 95%	LR	**0,8979** ± 0,0021	0,937	0,700

6 Configuração resultante e limitações

> **Configuração levada à Etapa 3:** limpeza F, *one-hot* com categorias raras agrupadas, padronização, sem redução de dimensionalidade. Random Forest é o melhor modelo até aqui (0,9742); para modelos lineares, usar a transformação `log` . O balanceamento fica entre "nenhum" e SMOTENC (com codificação ordinal), a decidir pela métrica de interesse: SMOTENC detecta mais anomalias, com mais falsos alarmes.

- **Estimativas otimistas.** Duplicatas e grupos conflitantes foram removidos de todo o treino antes da validação cruzada, e não só da parcela de treino de cada dobra. A base avaliada tem 3,3% de anomalias, contra 5,8% na original, e não contém os casos ambíguos, que estarão presentes no teste. O F1-macro esperado no teste deve ser menor que 0,974. Para a Etapa 3, a remoção deve passar para dentro do pipeline (aplicada apenas ao treino de cada dobra), com a validação mantendo todas as linhas.
- **Efeitos isolados.** Cada técnica foi avaliada separadamente, e as etapas usaram modelos de referência diferentes (LR na codificação e na redução; RF com ordinal no balanceamento). As interações ainda não foram testadas; a Etapa 3 deve comparar as melhores opções combinadas.
- **Poucas dobras.** Com três dobras, diferenças menores que um desvio-padrão não foram tratadas como ganho real.
- **Proveniência.** A exclusão dos atributos suspeitos se apoia no significado dos campos e no desempenho isolado; a origem deles não foi confirmada com quem produziu a base.

7 Próximas etapas

Para fechar o projeto, faltam: (i) incluir pelo menos um terceiro algoritmo (Árvore de Decisão, já disponível no pipeline, KNN ou rede neural); (ii) comparar as combinações vencedoras na mesma validação, com a remoção de conflitos dentro das dobras; (iii) ajustar o pipeline final em todo o treino e gerar `submissao_<número da equipe>.csv` , validando IDs, ordem e valores; e (iv) explicar o melhor modelo com *permutation importance* calculada na validação.

8 Reprodutibilidade e uso de IA generativa

Código e resultados: notebook do grupo no Google Colab e repositório github.com/IzadoraGalarza/TP1_G5_IA (base, notebook da Parte 2 e tabelas). Sementes fixadas em 42; scikit-learn [3] e imbalanced-learn [4]. Ferramentas de IA generativa (Claude, da Anthropic, e ChatGPT/Codex, da OpenAI) foram usadas como apoio na organização e depuração do código e na revisão do texto; as decisões e a interpretação dos resultados são da equipe.

[1] Tavallaee, M.; Bagheri, E.; Lu, W.; Ghorbani, A. A detailed analysis of the KDD CUP 99 data set. IEEE CISDA, 2009.

[2] Chawla, N. V. et al. SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 2002.

[3] Pedregosa, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2011.

[4] Lemaître, G.; Nogueira, F.; Aridas, C. K. Imbalanced-learn. Journal of Machine Learning Research, 18, 2017.