RELATÓRIO TÉCNICO

Análise exploratória dos dados — NSL-KDD

Caracterização, qualidade dos dados, redundâncias e investigação de possíveis vazamentos

Equipe do relatório

Daniel Alves Goncalves
Daniel Pedrosa Collina
Izadora Galarza Alves
Larissa Varella Araújo
Samuel Ferreira Alves Vieira

Link collab

https://colab.research.google.com/drive/17G_TeEmP-ekxSPhYF19qoXzsRnd6VD4h?usp=sharing

Trabalho_IA_Etapa_1.ipynb

Escopo do documento

Este relatório consolida os resultados exploratórios registrados para a base analisada, interpreta os achados à luz do benchmark NSL-KDD e apresenta recomendações para preservar a validade das próximas etapas. As conclusões distinguem evidências observadas de hipóteses que ainda dependem de confirmação da origem dos dados.

Indicadores centrais

- 69.833 registros e 50 colunas na base de trabalho.
- 65.754 registros normais (94,16%) e 4.079 anômalos (5,84%): aproximadamente 16,12 normais para cada anomalia.
- 292.542 células ausentes (8,38%) e 5.650 registros sinalizados por ao menos um tipo de verificação de qualidade.

Data de elaboração: 25 de outubro de 2026.

1. Resumo executivo

A análise exploratória examinou a estrutura e a distribuição das classes, valores ausentes, atributos constantes, duplicatas, grupos de registros com atributos iguais e rótulos conflitantes, faixas numéricas plausíveis, relações matemáticas entre variáveis derivadas, categorias textuais e associações que possam indicar vazamento de informação.

A base de trabalho contém 69.833 registros e 50 colunas. A distribuição é desbalanceada: 65.754 registros normais (94,16%) e 4.079 anômalos (5,84%). Um classificador que sempre previsse a classe normal já alcançaria 94,16% de acurácia, embora não detectasse nenhuma anomalia. Portanto, a acurácia isolada não será suficiente para julgar os modelos.

Foram identificadas 292.542 células ausentes (8,38% do total), um atributo constante (**num_outbound_cmds**), 11.355 registros sinalizados pela verificação de duplicatas exatas e 1.702 grupos em que os atributos coincidem, mas os rótulos divergem (3.730 linhas envolvidas nesses grupos). Também há valores numéricos fora das faixas esperadas, taxas superiores a 1, valores negativos em contagens/duração e variáveis derivadas matematicamente redundantes.

O achado de maior relevância para a modelagem é a associação de **tipo_alerta_soc** com a classe-alvo: a regra simples “ALERTA → anomalia; OK → normal” acerta 96,62% da base. O resultado é um sinal de alerta para investigar a origem e o momento em que esse campo é gerado, não uma demonstração de vazamento por si só. **score_ids_legado** e **tempo_resposta_analista_min** também requerem investigação de proveniência; recomenda-se excluí-los do modelo-base até essa verificação.

2. Objetivo, escopo e abordagem da análise

O objetivo desta etapa é compreender o conjunto de dados antes da modelagem, avaliar se as observações e os atributos são coerentes, identificar riscos de viés e deixar registradas decisões de tratamento justificáveis. A análise é exploratória e diagnóstica: ela não constitui treinamento de modelo, seleção final de atributos nem validação de desempenho preditivo.

2.1 Requisitos atendidos

Requisito da etapa	Como foi tratado no relatório
Caracterização da base NSL-KDD	Contextualização do benchmark e descrição da base efetivamente analisada, incluindo o alerta de que há campos não canônicos.
Identificação das classes e desbalanceamento	Contagem absoluta, proporção por classe, razão aproximada entre classes e consequência para a avaliação.
Atributos categóricos	Contagem de categorias e diagnóstico de variações apenas de capitalização.

Requisito da etapa	Como foi tratado no relatório
Inconsistências	Valores ausentes, constantes, negativos, valores fora das faixas esperadas e relações matemáticas entre variáveis.
Redundâncias	Duplicatas exatas, grupos com atributos iguais e rótulos conflitantes e atributos matematicamente derivados.
Possíveis vazamentos	Análise de **tipo_alerta_soc**, **score_ids_legado** e **tempo_resposta_analista_min**; recomendações para validação de proveniência.
Diagnóstico e encaminhamentos	Síntese de gravidade, cuidados de pré-processamento e plano para a etapa de modelagem.

2.2 Verificações realizadas

- Caracterização estrutural: número de linhas e colunas, distribuição de rótulos e tipos de atributos identificados na base.
- Completude: contagem e percentual de valores ausentes por atributo e no conjunto total; comparação da ausência de tempo de resposta entre as classes.
- Redundância: detecção de registros duplicados em todas as colunas e agrupamentos de atributos iguais com classe diferente.
- Plausibilidade numérica: validação dos limites esperados para contagens e taxas, inspeção de valores negativos e consulta à distribuição dos registros sinalizados por classe.
- Consistência interna: comparação de valores originais em bytes com seus equivalentes em kilobytes e verificação da soma usada em **total_bytes**.
- Categorias: contagem de valores distintos antes e depois de normalizar capitalização em **protocol_type**, **service** e **flag**.
- Risco de vazamento: comparação da classe entre categorias de **tipo_alerta_soc**, resumo de **score_ids_legado** por classe e distribuição de ausências de **tempo_resposta_analista_min** por classe.

As recomendações propostas abaixo partem desses resultados. Quando a evidência não permite escolher uma única correção — como nos valores fora de escala — o relatório mantém a ocorrência sinalizada e propõe validação com a fonte, em vez de aplicar uma transformação arbitrária.

3. Caracterização da base e contexto do NSL-KDD

O NSL-KDD é um conjunto de referência usado para avaliar sistemas de detecção de intrusão em redes. Ele foi criado como uma revisão do KDD Cup 1999 para reduzir problemas estatísticos associados à repetição excessiva de registros e melhorar a comparabilidade de experimentos. Cada observação do benchmark representa uma conexão de rede, com atributos básicos da conexão, atributos de conteúdo e atributos estatísticos de

tráfego. A versão tradicional é descrita com 41 atributos preditores e um rótulo; alguns arquivos de texto também contém o nível de dificuldade da observação [1, 2].

Esse contexto é importante, mas não deve ser confundido com a estrutura exata do dataframe utilizado neste projeto. A base analisada tem 69.833 linhas e 50 colunas e inclui campos como **tipo_alerta_soc**, **score_ids_legado**, **tempo_resposta_analista_min**, **src_bytes_kb**, **dst_bytes_kb** e **total_bytes**. Esses campos não fazem parte da lista tradicional de 41 atributos do NSL-KDD. Isso sugere que a base de trabalho foi enriquecida, transformada ou combinada com informações adicionais; a hipótese precisa ser confirmada pela documentação de origem e pelo histórico de preparação.

3.1 Limitações conhecidas do benchmark

O NSL-KDD é útil para exercícios controlados e comparações acadêmicas, mas representa tráfego derivado de experimentos de rede antigos, associados ao contexto DARPA de 1998. A própria documentação alerta que o conjunto não representa perfeitamente redes reais contemporâneas [1]. Por isso, resultados obtidos nele devem ser interpretados como resultados no benchmark analisado, sem extrapolar automaticamente para redes corporativas atuais.

3.2 Caracterização da base usada no projeto

Dimensão	Resultado ou observação
Registros	69.833.
Colunas	50, incluindo campos da classe e campos derivados/operacionais.
Rótulo utilizado	Duas classes analisadas: **normal** e **anomalia**.
Total de registros normais	65.754.
Total de registros anômalos	4.079.
Completude global	292.542 células ausentes, equivalentes a 8,38% de todas as células consideradas.
Origem/proveniência	A ser documentada: nomes e relações de alguns atributos indicam enriquecimento em relação ao esquema canônico.

4. Classes e desbalanceamento

A variável-alvo foi examinada em duas categorias: **normal** e **anomalia**. A classe normal representa a maior parte das observações, com 65.754 registros (94,16%). A classe anomalia contém 4.079 registros (5,84%). A razão entre as classes é de aproximadamente 16,12 registros normais para cada anômalo.

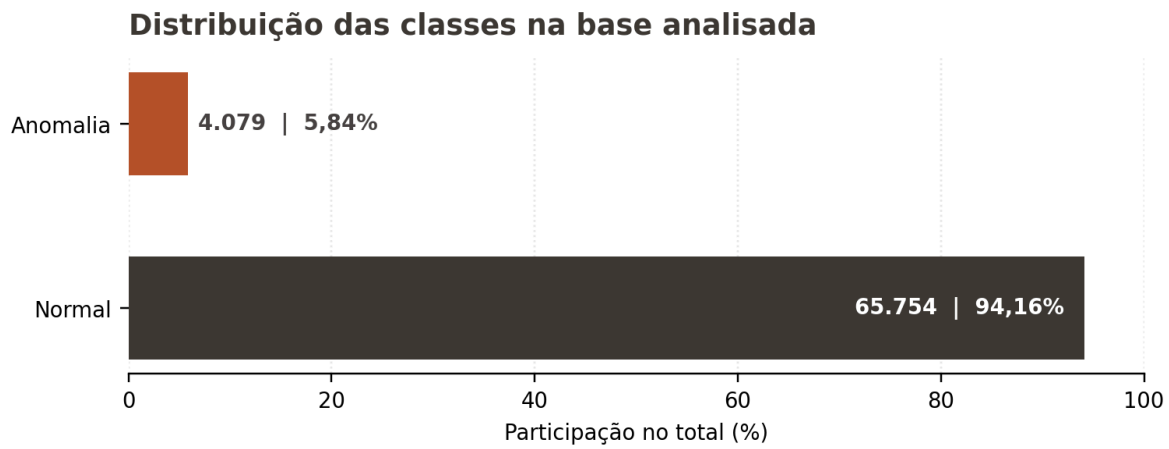


Figura 1. Distribuição das classes na base analisada. Percentuais calculados sobre 69.833 registros.

Classe	Quantidade	Participação
Normal	65.754	94,16%
Anomalia	4.079	5,84%
Total	69.833	100,00%

4.1 Consequências para a avaliação

Um preditor trivial que rotulasse todas as linhas como normais acertaria 65.754 de 69.833 casos, isto é, 94,16% de acurácia, mas teria recall de 0% para a classe anomalia. Esse exemplo mostra por que a acurácia isolada pode mascarar um modelo pouco útil para detecção de eventos raros.

Na etapa de modelagem, recomenda-se reportar matriz de confusão, precisão, recall da classe anomalia, F1 da classe anomalia, F1 macro e PR-AUC. Acurácia balanceada e ROC-AUC podem complementar a análise. A seleção do modelo deve considerar o custo dos falsos negativos (anomalias não detectadas) e dos falsos positivos (alertas indevidos), não apenas o percentual global de acertos.

Os números apresentados descrevem a base de trabalho atual. Eles não devem ser apresentados como a distribuição oficial de **KDDTrain+**, **KDDTest+** *ou de qualquer outro arquivo canônico específico sem confirmar qual arquivo foi usado e quais filtros foram aplicados.*

5. Valores ausentes e atributo constante

A verificação de completude contabilizou 292.542 células ausentes, correspondendo a 8,38% do total de células do dataframe. O percentual global resume o volume de ausência, mas não deve ser interpretado sozinho: a ausência está concentrada de forma muito desigual entre atributos e, em pelo menos um campo, apresenta associação expressiva com a classe-alvo.

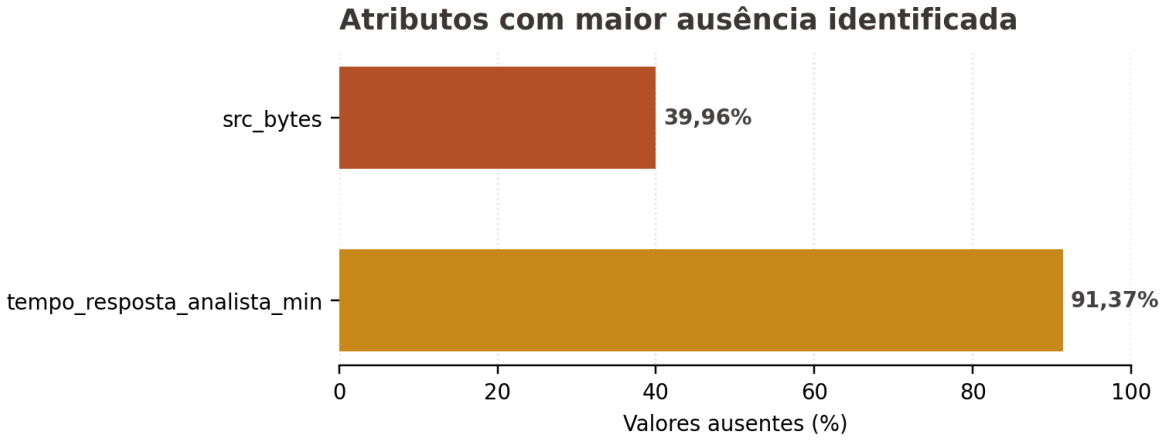


Figura 2. Percentual de valores ausentes nos dois atributos com contagens detalhadas destacadas na análise.

Atributo	Ausentes	Percentual	Consideração
tempo_resposta_analista_min	63.804	91,37%	Ausência muito elevada; também é fortemente associada à classe. Não imputar automaticamente.
src_bytes	27.906	39,96%	Ausência relevante; investigar se decorre de falha de coleta, transformação ou ausência estrutural.
Todos os atributos	292.542 células	8,38%	Estatística agregada da base analisada; a distribuição por atributo deve orientar o tratamento.

5.1 Ausência em `tempo_resposta_analista_min` por classe

Classe	Total na classe	Ausentes	Ausência na classe	Com valor observado	Mediana observada
Anomalia	4.079	960	23,54%	3.119	46,2 min
Normal	65.754	62.844	95,57%	2.910	12,5 min
Total	69.833	63.804	91,37%	6.029	—

A diferença entre classes é expressiva: 95,57% dos registros normais não têm tempo de resposta registrado, em comparação com 23,54% dos registros anômalos. Além disso, entre os valores observados, a mediana é 46,2 minutos para anomalias e 12,5 minutos para normais. Isso pode refletir o fluxo operacional de investigação de incidentes, e não uma

propriedade prévia da conexão de rede. Como o campo pode ser preenchido após a detecção ou atuação de um analista, há risco de vazamento de informação ou de uso de informação indisponível no momento de inferência.

5.2 Atributo constante

num_outbound_cmds foi identificado como atributo constante: todos os registros examinados apresentam o mesmo valor. Um atributo sem variação não discrimina as classes e não contribui para separar observações. Recomenda-se removê-lo do conjunto de preditores após registrar a verificação; a coluna deve permanecer na cópia bruta para rastreabilidade.

6. Duplicatas, redundâncias e rótulos conflitantes

6.1 Duplicatas exatas

A verificação de duplicatas considerando todas as colunas sinalizou 11.355 ocorrências. O número deve ser interpretado conforme a convenção usada pela rotina (por exemplo, linhas repetidas além da primeira, e não necessariamente o número de grupos distintos). Por isso, antes de remover registros, a implementação do notebook deve registrar explicitamente se a contagem corresponde a linhas marcadas por **duplicated()** ou a grupos de duplicação.

A ocorrência de repetições merece atenção porque o NSL-KDD foi concebido, em parte, para reduzir duplicatas redundantes presentes no KDD Cup 1999 [1, 2]. No entanto, esse resultado não prova que o arquivo oficial tenha sido usado sem modificações: a base atual parece conter atributos enriquecidos e pode ter sido reagrupada, unida, aumentada ou transformada após a obtenção do benchmark.

6.2 Atributos iguais com rótulos divergentes

Resultado	Quantidade	Interpretação
Grupos com atributos coincidentes e classe divergente	1.702 grupos	Os preditores observados não distinguem completamente as classes dentro desses grupos.
Registros envolvidos nesses grupos	3.730 linhas	Linhas em que existe ao menos uma divergência de rótulo dentro do grupo identificado.

Grupos com preditores iguais e classes diferentes podem refletir ruído de rotulagem, atributos relevantes ausentes (por exemplo, contexto temporal que não está no dataframe), critérios diferentes de rotulagem ou uma transformação que apagou informação discriminante. Eles não devem ser automaticamente tratados como erros: em algumas tarefas, a mesma assinatura observável pode ter rótulos distintos por razões legítimas. A origem dos rótulos e a definição de “anomalia” precisam ser verificadas.

6.3 Redundância matemática entre bytes

Três relações foram verificadas em pares comparáveis, e todas apresentaram zero inconsistências:

Relação verificada	Pares comparáveis	Inconsistências
src_bytes = src_bytes_kb × 1024	41.927	0
dst_bytes = dst_bytes_kb × 1024	69.833	0
total_bytes = src_bytes + dst_bytes	41.927	0

Essas relações demonstram que, nas linhas comparáveis, os campos derivados são matematicamente consistentes com os originais. Ao mesmo tempo, eles carregam informação determinística repetida. Manter todos pode ser desnecessário, especialmente em modelos sensíveis à escala, colinearidade ou à contagem de importância. Recomenda-se escolher uma representação principal (bytes originais ou derivados) e justificar a decisão, sem confundir redundância matemática com vazamento do rótulo.

6.4 Como lidar com duplicatas antes da divisão treino/teste

- Preservar uma cópia imutável da base bruta e registrar o critério de duplicação utilizado.
- Inspecionar duplicatas separadamente dentro de cada partição e entre treino e teste; se houver identificador de origem, manter esse rastreio.
- Evitar que cópias da mesma observação ou de um mesmo grupo derivado apareçam em treino e teste, o que pode inflar métricas.

- Resolver rótulos conflitantes apenas após verificar a fonte e as regras de rotulagem; se não for possível resolvê-los, documentar a opção de manter, excluir ou agrupar os casos em análise de sensibilidade.
- Não remover repetidos indistintamente quando frequência e repetição puderem ter significado operacional; a decisão deve refletir a unidade real de análise.

7. Inconsistências numéricas e plausibilidade dos valores

As verificações numéricas compararam valores observados com limites plausíveis para atributos de contagem e taxas, além de identificar valores negativos. Os limites usados são critérios de validação para a semântica esperada dos atributos no contexto NSL-KDD; uma ocorrência fora desses limites é um sinal de investigação, não uma autorização para alterar o valor automaticamente.

7.1 Contagens acima da faixa esperada

Atributo	Faixa esperada	Casos fora da faixa	Máximo observado
dst_host_count	0 a 255	912	256.000
count	0 a 511	464	512.000
srv_count	0 a 511	507	512.000

A magnitude dos máximos é incompatível com as faixas esperadas e é compatível com alguma hipótese de escala, formatação numérica ou transformação incorreta. O ponto deve ser confirmado consultando a origem dos valores, o código que construiu o dataframe e exemplos de linhas afetadas. A contagem de casos fora da faixa por atributo pode se sobrepor; não deve ser somada como se fossem registros distintos.

7.2 Taxas superiores ao intervalo [0, 1]

Os atributos interpretados como taxas deveriam estar entre 0 e 1. A análise identificou valores como 1,5, 2, 5 e 10, além das ocorrências listadas abaixo.

Atributo	Valores inválidos detectados
dst_host_srv_diff_host_rate	739
dst_host_srv_rerror_rate	714
rerror_rate	683
dst_host_same_srv_rate	670
dst_host_diff_srv_rate	623
Total de ocorrências nesses cinco campos	3.429

Ao contar por linha, 66.465 registros não apresentaram taxa inválida, 3.307 apresentaram exatamente um campo de taxa inválido e 61 apresentaram dois. Portanto, 3.368 registros (4,82% da base) foram afetados por ao menos uma das verificações de taxa. O total de 3.429 representa ocorrências em campos, não linhas únicas.

7.3 Valores negativos

Atributo	Negativos encontrados	Detalhe de classe entre os casos negativos
duration	358	343 normais e 15 anomalias; 323 dos valores são exatamente −1.
src_bytes	189	176 normais e 13 anomalias.
total_bytes	73	62 normais e 11 anomalias.
dst_bytes	0	Nenhum valor negativo detectado.
src_bytes_kb	Derivados	Os negativos são consequência direta da relação com src_bytes.
dst_bytes_kb	0	Nenhum negativo detectado.

Bytes transferidos e total de bytes não deveriam ser negativos em uma representação física direta. Para duration, entretanto, o valor −1 pode estar funcionando como sentinela para valor desconhecido ou ausente, e não necessariamente como duração real. Essa hipótese deve ser verificada na documentação de origem. Os demais negativos podem ter surgido por conversão, junção ou importação numérica incorreta. Por isso, o tratamento deve distinguir erro de representação de valor sentinela.

7.4 Investigação exploratória de possíveis fatores de escala

Foi realizado um teste diagnóstico: para cada valor fora da faixa, avaliou-se se dividir por fatores de 10, 100, 1.000 e 10.000 faria o resultado caber no intervalo esperado. Esse procedimento mede compatibilidade matemática, não comprova qual transformação gerou o problema.

Atributo	Casos fora da faixa	Após divisão por 10	por 100	por 1.000	por 10.000
count	464	291	363	251	10
srv_count	507	317	395	257	12
dst_host_count	912	171	360	174	16

As opções se sobrepõem: uma mesma observação pode caber no intervalo após mais de um fator; algumas observações não se ajustam aos fatores testados. Na análise de unicidade com fatores 10, 100 e 1.000, foram reportados os seguintes perfis: count (325 casos

compatíveis com múltiplos fatores, 57 apenas com 10, 39 apenas com 100, 32 apenas com 1.000 e 11 sem ajuste); **srv_count** (366, 67, 33, 31 e 10, respectivamente); **dst_host_count** (130 compatíveis com múltiplos, 109 apenas com 10, 237 apenas com 100, 96 apenas com 1.000 e 340 sem ajuste).

7.5 Quantidade geral de registros sinalizados

Quantidade de tipos de problema identificados por linha	Registros	Percentual
Nenhum tipo sinalizado	64.183	91,91%
Um tipo sinalizado	5.531	7,92%
Dois tipos sinalizados	119	0,17%
Ao menos um tipo sinalizado	5.650	8,09%

Esses totais representam as categorias de verificações reunidas na contagem por linha. Não significam que as demais 64.183 linhas foram comprovadas como perfeitas em todos os aspectos; significam apenas que não foram marcadas pelos tipos de problemas incluídos nessa rotina. Também não se deve somar as quantidades por atributo sem deduplicar as linhas, pois um mesmo registro pode violar mais de uma regra.

8. Atributos categóricos e normalização

Foram examinados os níveis distintos de **protocol_type**, **service** e **flag**, com uma segunda contagem após converter valores textuais para minúsculas. O objetivo foi identificar se diferenças na capitalização estavam criando categorias artificiais.

Atributo	Níveis originais	Após normalizar capitalização	Diagnóstico
protocol_type	6	3	As diferenças correspondem a **ICMP/icmp**, **TCP/tcp** e **UDP/udp**.
service	67	67	Nenhuma duplicidade de categoria causada apenas por capitalização foi detectada.
flag	19	11	Oito pares de variações de capitalização foram consolidados.

Para **flag**, os pares encontrados foram **REJ/rej**, **RSTO/rsto**, **RSTR/rstr**, **S0/s0**, **S1/s1**, **S2/s2**, **S3/s3** e **SF/sf**. No caso de **protocol_type**, os pares foram **ICMP/icmp**, **TCP/tcp** e **UDP/udp**.

8.1 Decisão de pré-processamento

- Preservar os valores originais na camada bruta para que a normalização seja reversível e auditável.
- Criar uma representação normalizada de **protocol_type** e **flag** (por exemplo, com **lower()** e remoção de espaços periféricos, desde que a análise confirme que espaços são ruído).
- Validar as categorias observadas após a normalização e manter uma tabela de mapeamento do valor original para o normalizado.
- Tratar atributos categóricos como categorias, sem impor uma ordem numérica artificial. A codificação (por exemplo, one-hot) deve ser ajustada apenas com os dados de treino e aplicada de forma consistente aos demais conjuntos.
- Não alterar **service** apenas por uniformidade: a verificação não encontrou duplicidades de caixa nesse atributo.

9. Investigação de possíveis vazamentos de dados

Vazamento de dados ocorre quando o modelo recebe informação que não estaria disponível no momento da previsão ou que incorpora, direta ou indiretamente, o rótulo que se pretende prever. Uma associação forte entre atributo e classe é motivo para investigar sua origem, mas não prova isoladamente a existência de vazamento. A decisão depende da definição operacional do problema e do momento de disponibilidade do campo.

9.1 `tipo_alerta_soc`

Valor	Anomalia	Normal	Total	Anomalia dentro do grupo
ALERTA	3.379	1.657	5.036	67,10%
OK	700	64.097	64.797	1,08%
Total	4.079	65.754	69.833	5,84%

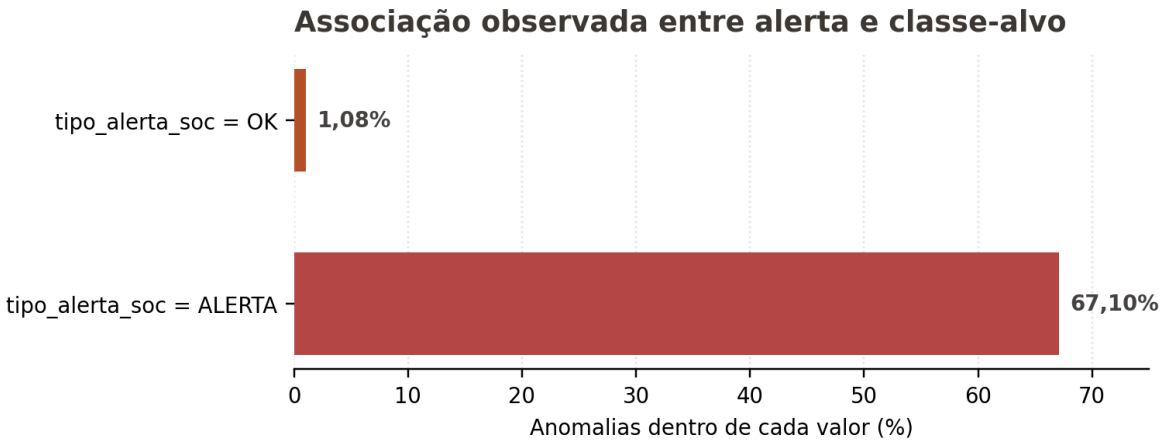


Figura 3. Proporção de anomalias dentro de cada categoria de `tipo_alerta_soc`; associação descritiva, não avaliação de modelo.

A regra ilustrativa “ALERTA → anomalia; OK → normal” classificaria corretamente 67.476 dos 69.833 registros, uma acurácia aparente de 96,62%. A regra identificaria 3.379 das 4.079 anomalias (recall de 82,84%), mas 1.657 registros marcados como alerta são normais segundo a variável-alvo. Entre os registros classificados como **OK**, 700 ainda são anomalias.

A acurácia aparente da regra é superior à linha de base que prevê sempre a classe normal (94,16%), mas essa diferença não é evidência de que o campo será um bom preditor em produção. Se **tipo_alerta_soc** for produzido por um mecanismo de detecção que já utiliza sinais semelhantes ou o próprio rótulo após a análise do incidente, incluí-lo pode tornar a tarefa circular. Se for um sinal independente que existe antes da decisão, pode ser legítimo. É indispensável documentar a origem, a regra de geração e o instante em que a variável fica disponível.

9.2 `score_ids_legado`

Estatística	Anomalia (n=4.079)	Normal (n=65.754)
Média	0,7069	0,1580
Mediana	0,818	0,126
Mínimo	0	0
Percentil 75	0,904	0,199
Percentil 95	1,000	0,375
Máximo	1,000	1,000

O score apresenta valores muito mais altos para anomalias do que para registros normais. O contraste pode representar um sinal legado legítimo, mas também pode indicar que o campo foi criado por um sistema anterior de detecção, derivado de uma regra próxima à variável-alvo ou calculado após o evento. O nome do campo e a diferença entre classes justificam investigar sua fórmula e a cronologia de geração; não permitem afirmar a existência de vazamento sem essa informação.

9.3 `tempo_resposta_analista_min`

A taxa de ausência é de 95,57% para registros normais e de 23,54% para anomalias, e a mediana observada é de 12,5 minutos para normais e 46,2 minutos para anomalias. Como o tempo de resposta provavelmente pertence ao fluxo de operação do SOC, é plausível que seja registrado depois da geração de um alerta ou do início da investigação. Se a aplicação pretende prever uma anomalia antes desse fluxo, utilizar o campo ou a própria ausência pode revelar informação sobre o processo posterior à classe.

Recomendação: excluir o campo do modelo-base e não transformar sua ausência em uma variável indicadora para modelagem sem examinar o processo de coleta. Uma análise posterior só é justificável se o objetivo for, por exemplo, priorizar a resposta operacional após a criação do alerta e se esse dado estiver de fato disponível nesse ponto do fluxo.

9.4 Controles gerais contra vazamento

- Definir de forma explícita o instante da previsão: antes da conexão, durante a conexão, após um alerta ou após a investigação.
- Classificar cada atributo segundo sua disponibilidade temporal e sua origem (sensor, feature engineering, regra de alerta, sistema legado, analista, rótulo).
- Excluir do treino inicial atributos produzidos depois da decisão-alvo ou cujo cálculo use direta ou indiretamente a classe.
- Calcular imputação, normalização, seleção de atributos, codificação, balanceamento e qualquer estatística aprendida somente a partir do conjunto de treino.
- Usar o particionamento oficial do benchmark, caso tenha sido preservado; caso contrário, construir uma separação rastreável que evite que duplicatas/grupos relacionados cruzem treino e teste.
- Comparar um baseline sem campos suspeitos com cenários de ablação, sem tratar o melhor resultado como válido até confirmar disponibilidade operacional.

10. Relação entre problemas de qualidade e classe

Foram comparadas as proporções de registros que receberam sinalização por três grupos de verificações. A comparação ajuda a entender se os problemas de qualidade estão concentrados em uma das classes. As porcentagens são calculadas dentro de cada classe, não sobre a base inteira.

Grupo de verificação	Anomalias sinalizadas	% das anomalias	Normais sinalizados	% dos normais
Taxas fora do intervalo	200 / 4.079	4,90%	3.168 / 65.754	4,82%
Contagens fora dos limites	112 / 4.079	2,75%	1.743 / 65.754	2,65%
Valores negativos	28 / 4.079	0,69%	518 / 65.754	0,79%

As proporções são próximas para taxas e contagens, de modo que, segundo essas verificações, as inconsistências não parecem ocorrer exclusivamente em anomalias. A porcentagem de registros sinalizados por negativos é um pouco maior na classe normal, apesar de a classe normal ter mais registros em termos absolutos. Esse padrão reforça que não é adequado excluir todos os casos com inconsistência sem avaliar como o tratamento alterará a composição das classes.

Essas contagens se referem aos registros sinalizados por grupo de regra. Como uma linha pode infringir mais de uma regra, os totais entre grupos não devem ser somados para estimar quantas linhas únicas têm problema; para isso deve ser utilizada a contagem agregada por linha apresentada na Seção 7.5.

11. Decisões recomendadas para o pré-processamento

A análise exploratória não deve converter todos os achados diretamente em exclusões ou imputações. O tratamento proposto abaixo privilegia rastreabilidade e evita introduzir correções sem evidência suficiente.

Achado	Decisão recomendada	Justificativa / condição
num_outbound_cmds constante	Remover do conjunto de preditores após registrar a constância.	Não oferece variação para separar classes.
Capitalização em **protocol_type** e **flag**	Normalizar em colunas tratadas e manter os valores originais.	Reduz níveis artificiais duplicados por caixa.
service sem duplicidade de caixa	Manter categorias; validar níveis raros/desconhecidos na próxima fase.	Não há evidência de que a caixa gere categorias repetidas.
src_bytes com 39,96% ausentes	Investigar origem; decidir imputação e/ou indicador apenas após a análise do mecanismo de ausência.	Percentual alto é possível em relação a atributos derivados.
tempo_resposta_analista_min com 91,37% ausentes	Excluir do baseline até validar momento de disponibilidade e risco de vazamento.	Ausência e valor observado diferem fortemente por classe.
tipo_alerta_soc	Excluir do baseline até documentar a origem; analisar separadamente se justificável.	Regra associada à classe tem acurácia aparente de 96,62%.
score_ids_legado	Excluir do baseline até auditar cálculo e cronologia; comparar por ablação depois.	Separação numérica forte entre as classes.
Contagens e taxas fora da faixa	Manter sinalizações e validar com a fonte antes de corrigir.	O fator de escala não é unívoco.
Negativos em duração/bytes	Investigar −1 como possível sentinela; revisar conversões de bytes.	Sem documentação, não distinguir com segurança sentinela de corrupção.
Duplicatas exatas	Resolver após verificar a unidade de análise e a separação treino/teste.	Remoção cega pode apagar repetições válidas ou ocultar fuga entre partições.
Atributos coincidentes com rótulos divergentes	Auditar regras de rotulagem; executar análise de sensibilidade se irresolúvel.	Possível ambiguidade da classe ou informação ausente.

Achado	Decisão recomendada	Justificativa / condição
Bytes e campos derivados	Escolher a representação principal e documentar.	Há redundância determinística sem inconsistências nos pares comparáveis.

12. Limitações da análise e pontos ainda a confirmar

O diagnóstico é suficientemente detalhado para a entrega da etapa exploratória, mas algumas conclusões dependem de informações que não podem ser inferidas apenas das estatísticas sumarizadas. As limitações devem permanecer explícitas no relatório e no notebook.

- Proveniência dos campos adicionais: é necessário identificar como **tipo_alerta_soc**, **score_ids_legado**, **tempo_resposta_analista_min**, **total_bytes**, **src_bytes_kb** e **dst_bytes_kb** foram criados e em que momento estariam disponíveis.
- Origem do recorte: confirmar o arquivo NSL-KDD inicial, a versão (por exemplo, treino/teste), filtros, junções, amostragem, balanceamento, enriquecimentos e transformações anteriores.
- Duplicatas: explicitar o algoritmo e a convenção de contagem usados para chegar a 11.355 ocorrências; examinar duplicatas entre partições.
- Escalas numéricas: fator de divisão não é unívoco; precisa ser confirmado com documentação ou arquivo original.
- Rótulos conflitantes: sem acesso à regra de criação dos rótulos, não é possível determinar se as 1.702 combinações são erros de rotulagem ou ambiguidade legítima.
- Generalização: o NSL-KDD é um benchmark histórico. O diagnóstico não demonstra que padrões serão os mesmos em tráfego atual.
- Análise univariada e multivariada: os resultados aqui documentados cobrem os testes citados; não equivalem a uma auditoria completa de todas as distribuições, correlações, valores extremos e deriva temporal.

13. Organização sugerida para o notebook da Etapa 1

Para que o notebook atenda ao requisito de análise exploratória e breve diagnóstico de forma reprodutível, recomenda-se que cada resultado deste relatório tenha uma célula de código e uma saída verificável. A organização abaixo não substitui a implementação do notebook: serve como roteiro para manter a ordem lógica da análise e facilitar a correção.

1. Identificação da fonte: caminho/nome do arquivo, versão, data de obtenção, descrição da variável-alvo e histórico de transformações conhecidas.
2. Carregamento e inspeção inicial: dimensões, amostra de linhas, nomes de colunas, tipos de dados e conversão explícita do rótulo normal/anomalia.
3. Caracterização da variável-alvo: contagens, proporções, razão de desbalanceamento e gráfico da distribuição de classes.
4. Completude e constância: tabela de nulos por coluna, percentuais, mapa de ausência se útil, total de células ausentes e lista de atributos constantes.

5. Duplicatas: contagem em todas as colunas, identificação de grupos e análise de atributos iguais com rótulo divergente.
6. Qualidade numérica: tabelas de limites plausíveis, frequências dos valores inválidos, negativos e quantidade de linhas afetadas, com comparação por classe.
7. Consistência matemática: assertivas ou comparações de **src_bytes**, **dst_bytes**, versões em KB e **total_bytes**, incluindo o número de pares comparáveis.
8. Categorias: níveis distintos antes/depois da normalização de capitalização, além de tabela de mapeamento dos níveis consolidados.
9. Possíveis vazamentos: tabelas cruzadas e distribuições de **tipo_alerta_soc**, **score_ids_legado** e ausência de **tempo_resposta_analista_min** por classe.
10. Diagnóstico final: lista priorizada de problemas, decisões que já podem ser aplicadas e pendências que exigem confirmação da fonte.

O notebook deve conservar os resultados das verificações, evitar sobrescrever a base bruta e documentar qualquer correção em uma etapa posterior. Quando a modelagem começar, transformações que aprendem parâmetros (imputação, escala, codificação, seleção de atributos e reamostragem) devem ser ajustadas exclusivamente com treino.

14. Conclusão

A análise exploratória cumpriu o objetivo de caracterizar a base de trabalho e identificar pontos que precisam ser considerados antes da modelagem. A distribuição binária é desbalanceada (94,16% normal e 5,84% anomalia), há uma quantidade relevante de valores ausentes, **num_outbound_cmds** não varia, foram sinalizadas duplicatas e grupos com rótulos divergentes, há valores numéricos fora de limites plausíveis e parte das features é matematicamente redundante.

Os problemas de escala e os valores negativos precisam de tratamento baseado em evidências da fonte, não de correções automáticas. As categorias **protocol_type** e **flag** devem ser normalizadas de modo rastreável. As relações entre as colunas de bytes foram consistentes nas linhas comparáveis, mas a redundância das colunas derivadas deve ser considerada no desenho do conjunto de preditores.

O principal risco metodológico é a possível utilização de informação operacional ou posterior ao evento. A associação de **tipo_alerta_soc**, os valores de **score_ids_legado** e o padrão de ausência de **tempo_resposta_analista_min** justificam que esses campos sejam excluídos do baseline até que sua origem e disponibilidade temporal sejam documentadas. Também é importante confirmar se a base preserva os particionamentos oficiais do NSL-KDD e como as duplicatas e os rótulos conflitantes surgiram.

Portanto, a base está caracterizada o suficiente para concluir a etapa exploratória e avançar para a preparação controlada dos dados. A próxima etapa deve começar com uma base bruta preservada, um protocolo de limpeza auditável e uma definição explícita do momento da previsão. A avaliação de qualquer modelo deverá priorizar a detecção da classe minoritária e prevenir que duplicatas, transformações ou atributos pós-evento gerem métricas artificialmente otimistas.

Apêndice A. Quadro consolidado dos principais achados

Área	Achado observado	Nível de atenção	Encaminhamento
Classes	94,16% normal; 5,84% anomalia.	Alto para avaliação	Não usar acurácia isolada; reportar recall/F1/PR-AUC da anomalia.
Ausência	292.542 células (8,38%); **tempo_resposta_analista_min** 91,37%; **src_bytes** 39,96%.	Alto	Investigar mecanismo de ausência e vazamento antes de imputar.
Constante	**num_outbound_cmds**.	Baixo, simples de tratar	Remover os preditores após registrar o achado.
Duplicatas	11.355 ocorrências sinalizadas.	Alto antes da divisão	Confirmar a convenção de contagem e sobreposição entre partições.
Rótulos conflitantes	1.702 grupos / 3.730 linhas.	Alto	Auditar rótulos, atributos omitidos e contexto de geração.
Contagens	**dst_host_count**, **count**, **srv_count** fora da faixa.	Alto	Validar escala com fonte; não corrigir automaticamente.
Taxas	Valores acima de 1 em cinco atributos listados.	Alto	Validar escala ou conversão; 3.368 linhas afetadas por taxa inválida.
Negativos	**duration**, **src_bytes**, **total_bytes**.	Médio/alto	Investigar −1 como sentinela e revisar cálculos/importação.
Derivação de bytes	Três identidades matemáticas sem inconsistências em pares comparáveis.	Médio	Selecionar representação para reduzir redundância.
Categóricos	**protocol_type** 6→3; **flag** 19→11; **service** permanece 67.	Médio	Normalizar caixa em atributos com duplicatas de capitalização.

Área	Achado observado	Nível de atenção	Encaminhamento
Vazamento potencial	**tipo_alerta_soc**, **score_ids_legado**, **tempo_resposta_analista_min**.	Muito alto	Excluir do baseline até provar disponibilidade antes da predição.

Apêndice B. Fórmulas e definições usadas na interpretação

- Percentual por classe = quantidade da classe ÷ total de registros × 100.
- Razão de desbalanceamento = quantidade da classe majoritária ÷ quantidade da classe minoritária = 65.754 ÷ 4.079 ≈ 16,12.
- Acurácia ilustrativa da regra **tipo_alerta_soc** = (anomalias com **ALERTA** + normais com **OK**) ÷ total = (3.379 + 64.097) ÷ 69.833 ≈ 96,62%.
- Recall ilustrativo da regra para anomalias = anomalias com **ALERTA** ÷ todas as anomalias = 3.379 ÷ 4.079 ≈ 82,84%.
- Percentuais de ausência por classe utilizam o total de cada classe como denominador, e não o número total de ausentes.
- Os números de valores inválidos por atributo representam ocorrências por coluna; quando a mesma linha viola mais de uma regra, os totais por atributo podem se sobrepor.

Referências

[1] CANADIAN INSTITUTE FOR CYBERSECURITY, UNIVERSITY OF NEW BRUNSWICK. *ISCX NSL-KDD dataset 2009.* Página institucional com a descrição do conjunto, arquivos e problemas estatísticos do KDD'99. Acesso em: 25 out. 2026. https://www.unb.ca/cic/datasets/nsl.html

[2] TAVALLAEE, Mahbod; BAGHERI, Ebrahim; LU, Wei; GHORBANI, Ali A. *A Detailed Analysis of the KDD CUP 99 Data Set.* In: IEEE Symposium on Computational Intelligence for Security and Defense Applications (CISDA), 2009. DOI: 10.1109/CISDA.2009.5356528. https://doi.org/10.1109/CISDA.2009.5356528

[3] IEEE TECHNOLOGY NAVIGATOR. *NSL-KDD.* Síntese sobre estrutura, finalidade e limitações do benchmark. Acesso em: 25 out. 2026. https://technav.ieee.org/topic/nsl-kdd/